

TD : Classification supervisée

Master 1 MIAAGE
Introduction au Web sémantique et au Data Mining
Université d'Orléans

TD issu des supports de Christel Vrain

1 Exercice : Arbre de décision

Représentez les fonctions booléennes suivantes par un arbre de décision : $A \wedge \neg B$, $A \text{ X-OR } B$.

Pour résoudre l'exercice, il faut d'abord construire l'ensemble d'apprentissage. Pour ce faire, nous considérons A , B et C comme des attributs qui peuvent prendre 0 ou 1 comme valeurs ; la sortie désirée est le résultat de la fonction booléenne.

Point important : les exercices suivants ont pour unique but de comprendre le fonctionnement d'un algorithme d'apprentissage. Les bases de données sont bien trop petites pour que les résultats obtenus puissent être utilisés en classification.

2 Exercice : Gain d'information, Bayes et k-nn

Soient les exemples suivants :

no	A1	A2	A3	Classe
1	1	0	1	+
2	1	1	1	+
3	1	1	0	-
4	0	0	0	+
5	0	0	1	-
6	0	1	1	-

2.1 Entropie

- Quelle est l'entropie¹ de ces exemples pour l'attribut Classe ?
- Quel est le gain d'information pour l'attribut A_2 ?
- Construisez l'arbre de décision.
- Comment serait classée l'observation o vérifiant $A_1 = 1$, $A_2 = 0$, $A_3 = 0$?
- Quand la valeur de l'entropie est-elle maximale, minimale ?

2.2 Indice de Gini

En utilisant l'indice de Gini, quel est l'indice de Gini de l'attribut Classe ? Quel est le gain d'information pour l'attribut A_2 ?

1. Quelques valeurs de $\log_2 x$:

x	1	1/4	2/3	3/4	1/3	1/2
$\log_2(x)$	0	-2	-0.6	-0.4	-1.6	-1

2.3 Classifieur bayésien naïf


Comment un classifieur bayésien naïf classerait l'observation o précédente ?

2.4 k-ppv (k-nn)

Comment un algorithme de k-ppv (k-nn) classerait l'observation o précédente, en prenant $k = 3$?

3 Exercice : Frontière de décision

Les arbres de décision divisent l'espace en rectangles parallèles aux axes et étiquettent chaque rectangle avec l'une des classes. Quelles sont les frontières de décision pour l'arbre de décision pour la figure suivante ? (les nœuds feuilles sont étiquetés avec les classes (C1/C2) et la branche gauche de chaque nœud correspond toujours à la réponse oui, l'autre branche à la réponse non)



4 Exercice : Évaluation d'un classifieur

En classification supervisée, la validation d'un modèle appris est plus facile puisque l'on dispose en général de données étiquetées (on connaît la classe des données) et on cherche un modèle qui puisse prédire la classe d'une nouvelle observation.

4.1 Cas à 2 classes

On met l'accent sur un concept : les observations vérifiant ce concept sont appelées exemples en français ou exemples positifs, ils forment la première classe. Les observations ne vérifiant pas ce concept sont appelées contre-exemples en français ou exemples négatifs, ils forment l'autre classe.

On considère les données suivantes et on souhaite apprendre un classifieur pour la classe *Play* :

Ensemble d'apprentissage					
Number	Outlook	Temperature	Humidity	Windy	Play
1	rainy	mild	normal	false	yes
2	rainy	cool	normal	false	yes
3	rainy	cool	normal	false	yes
4	sunny	hot	high	false	no
5	rainy	cool	normal	false	yes
6	sunny	mild	high	false	no
7	sunny	cool	normal	false	yes
8	rainy	cool	normal	true	no

On suppose qu'à partir de ces données, on apprend l'arbre de décision suivant AD1 :

```

humidity = high: no
humidity = normal
| windy = TRUE: no
| windy = FALSE: yes

```

- (a) Calculez le nombre d'erreurs fait par AD1 sur l'ensemble d'apprentissage (erreur de resubstitution)
- (b) Construisez la matrice de confusion définie par :

Observed or real class	Predicted Class	
	yes	no
yes	true positive (TP)	false negative (FN)
no	false positive (FP)	true negative (TN)

- (c) Calculez les mesures suivantes :
- $\frac{TP+TN}{TP+TN+FP+FN}$: taux de classification correcte (accuracy)
 - $\frac{FP+FN}{TP+TN+FP+FN}$: taux d'erreur (error rate)
 - $\frac{TP}{TP+FP}$: précision (precision, confidence)
 - $\frac{TP}{TP+FN} = \frac{TP}{POS}$: rappel (recall, true positive rate, sensitivity)
- (d) Le taux d'erreur en resubstitution est en général faible puisque l'on a entraîné le modèle pour qu'il fasse peu d'erreurs sur ces données. Pour évaluer vraiment la qualité du modèle appris, il faut tester le modèle sur des données qui n'ont pas été utilisées pour l'apprentissage.

On considère maintenant l'ensemble test suivant :

Ensemble de test					
Number	Outlook	Temperature	Humidity	Windy	Play
1	overcast	mild	high	true	yes
2	rainy	cool	normal	false	yes
3	sunny	hot	high	true	no
4	sunny	mild	high	false	no
5	overcast	cool	normal	true	yes
6	overcast	cool	normal	true	yes
7	sunny	hot	high	false	no

Calculez sur cet ensemble test le nombre d'erreurs fait par AD1. Construisez la matrice de confusion. Calculez le taux de classification correcte, le taux d'erreur, la précision, le rappel.

4.2 Cas à 3 classes

Soient les données suivantes, décrites par 4 attributs pb, astigmatisme, larme et lentille :

Ensemble d'apprentissage			
pb	astigmatisme	larme	lentille
myope	oui	normal	rigide
myope	non	réduit	aucune
myope	oui	réduit	aucune
hypermétrope	non	normal	souple
hypermétrope	non	réduit	aucune
hypermétrope	oui	normal	rigide
myope	oui	normal	rigide

On suppose que l'on veut prédire la classe lentille et que l'on a construit l'arbre de décision AD2 suivant :

```
larme = réduit: aucun
larme = normal
| astigmatisme = non: souple
| astigmatisme = oui
| | pb = myope: rigide
| | pb = hypermétrope: aucun
```

- (a) Calculez le nombre d'erreurs fait par AD2 sur l'ensemble d'apprentissage (erreur de resubstitution)
- (b) Construisez la matrice de confusion. Calculez le taux de classification correcte et le taux d'erreur. Les notions de précision et de rappel ont-elles un sens ?
- (c) On considère maintenant l'ensemble test suivant :

Ensemble de test			
pb	astigmatisme	larme	lentille
myope	non	réduit	aucun
myope	non	normal	aucun
myope	oui	normal	rigide
hypermétrope	non	réduit	aucun
hypermétrope	non	normal	souple
hypermétrope	oui	normal	aucun

Calculez le nombre d'erreurs fait par AD2 sur l'ensemble test. Construisez la matrice de confusion. Calculez le taux de classification correcte et le taux d'erreur.